

인공지능의 이해

Understanding Artificial Intelligence

유준수 (Joon Soo Yoo, Ph.D.)

Fall 2026

Defense & Advanced Security Lab (DAS Lab)

Department of Advanced Defense Technology and Industry

Jeonbuk National University

Classification and Model Evaluation

From Classification to Model Evaluation

Week 4

Learning Objectives

이번 Week에서는 Classification Model을 만들고 그 성능을 평가하는 방법을 학습한다.

Learning Goals

- ▶ Regression과 Classification의 차이를 이해한다.
- ▶ Logistic Regression의 기본적인 동작을 이해한다.
- ▶ Feature에 따라 학습된 Model이 달라질 수 있음을 이해한다.
- ▶ Accuracy와 Confusion Matrix를 이해한다.
- ▶ Precision, Recall, F1 Score의 의미를 이해한다.
- ▶ Threshold가 Classification 결과에 미치는 영향을 이해한다.
- ▶ Cross Validation의 필요성을 이해한다.
- ▶ ROC Curve와 AUC의 기본 개념을 이해한다.

1. From Regression to Classification

지난 Week에서는 Regression을 학습했다.

Study Hours
↓
Linear Regression
↓
Exam Score = 82.4

이번에는 숫자가 아니라 Category를 Prediction하고 싶다.

Penguin Features
↓
Classification Model
↓
Adelie / Gentoo

핵심

Regression은 Numerical Value를 예측하고, Classification은 Class 또는 Category를 예측한다.

1-1. Classification Examples

Classification은 우리 주변의 다양한 문제에 사용된다.

Input	Class
Penguin Features	Adelie / Gentoo
Email	Spam / Normal
Image	Cat / Dog
Medical Data	Disease / Normal
Network Data	Attack / Normal

두 개의 Class를 구분하는 문제를 Binary Classification이라고 한다.

Class 0 vs. Class 1

핵심

Binary Classification은 Input Data를 두 개의 Class 중 하나로 분류하는 문제이다.

2. Our Dataset: Palmer Penguins

이번 Week에서는 실제 Penguin Data를 사용한다.

Palmer Penguins Dataset에는 여러 Penguin의 신체 특징이 기록되어 있다.

대표적인 Feature는 다음과 같다.

- ▶ Bill Length
- ▶ Bill Depth
- ▶ Flipper Length
- ▶ Body Mass

이번 실습에서는 두 Penguin Species를 분류한다.

Adelie

vs.

Gentoo

핵심

Penguin의 신체 특징을 Feature로 사용하여 Penguin Species를 Classification한다.

2-1. Features and Label

이번 Classification Problem에서 Feature와 Label을 구분해보자.

Type	Data
Feature	Bill Length
Feature	Flipper Length
Feature	Body Mass
Label	Species

Label은 다음과 같이 표현할 수 있다.

Adelie = 0

Gentoo = 1

핵심

Feature는 Model이 Species를 판단하기 위해 사용하는 정보이고, Label은 실제 Penguin Species이다.

2-2. Classification as a Boundary

두 개의 Feature를 사용하면 Data를 2차원 공간에 표현할 수 있다.

예를 들어,

x-axis = Bill Length

y-axis = Flipper Length

각 Penguin은 하나의 Point가 된다.

Adelie: • • •

Gentoo: × × ×

Classification Model은 두 Group을 구분하는 Decision Boundary를 학습할 수 있다.


핵심

Classification은 Feature Space에서 서로 다른 Class를 구분하는 문제로 생각할 수 있다.

3. Logistic Regression

이번 Week에서는 Logistic Regression을 사용한다.

이름에는 Regression이 들어 있지만, Logistic Regression은 대표적인 Classification Model이다.



핵심

Logistic Regression은 Input Feature를 이용하여 Class에 속할 가능성을 계산하고 Classification에 사용할 수 있다.

3-1. From Probability to Class

Logistic Regression은 Class에 대한 Probability를 계산할 수 있다.

예를 들어,

Penguin Features



Logistic Regression



$P(\text{Gentoo}) = 0.83$

Threshold가 0.5라고 하면,

$P(\text{Gentoo}) < 0.5 \rightarrow \text{Adelie}$

$P(\text{Gentoo}) \geq 0.5 \rightarrow \text{Gentoo}$

핵심

Probability를 Threshold와 비교하여 최종 Class Prediction을 결정할 수 있다.

3-2. (참고) Logistic Regression Formula

여러 Feature를 사용하는 경우 먼저 다음과 같은 값을 계산할 수 있다.

$$z = w_1x_1 + w_2x_2 + \dots + w_dx_d + b$$

그리고 Logistic Function을 적용한다.

$$\sigma(z) = \frac{1}{1 + e^{-z}}$$

결과는 0과 1 사이의 값이 된다.

$$0 < \sigma(z) < 1$$

이를 Class Probability로 사용할 수 있다.

$$P(y = 1|x) = \sigma(w^T x + b)$$

참고


Training은 Data를 잘 분류할 수 있도록 Weight w 와 Bias b 를 학습하는 과정이다.

3-3. Same Algorithm, Different Models

같은 Logistic Regression을 사용해도 어떤 Feature를 사용하는지에 따라 Model은 달라진다.

Model	Features
Model A	Bill Length
Model B	Bill Length + Flipper Length
Model C	Bill Length + Flipper Length + Body Mass

각 Model은 서로 다른 Input을 이용하여 Species를 Classification한다.




핵심

같은 Learning Algorithm을 사용해도 Feature와 Training Data가 달라지면 학습된 Model도 달라질 수 있다.

4. Training a Classification Model

Classification에서도 Machine Learning Workflow는 동일하다.



Python에서는 다음과 같은 구조를 사용한다.

Source Code

```
model.fit(X_train, y_train)
prediction = model.predict(X_test)
```

핵심

Regression과 Classification은 Model은 다르지만, Training과 Prediction의 기본 Workflow는 동일하다.

4-1. Train Three Classification Models

이번에는 세 개의 Logistic Regression Model을 만든다.

Model	# Features	Input
A	1	Bill Length
B	2	Bill Length, Flipper Length
C	3	Bill Length, Flipper Length, Body Mass

모든 Model은 같은 문제를 해결한다.

Penguin Features → Adelie / Gentoo

하지만 사용 가능한 Information이 다르다.

질문

Feature를 더 많이 사용하는 Model이 항상 더 좋은 Classification 성능을 보일까?

4-2. Are More Features Always Better?

Feature가 많아지면 Model이 더 많은 Information을 사용할 수 있다.

하지만 Feature가 많다고 해서 항상 더 좋은 Model이 되는 것은 아니다.

추가된 Feature가 다음과 같을 수도 있다.

- ▶ Prediction에 도움이 되는 Feature
- ▶ 거의 관계없는 Feature
- ▶ Noise가 많은 Feature
- ▶ 다른 Feature와 중복되는 Feature

따라서 실제 성능을 측정하여 비교해야 한다.

핵심

좋은 Feature를 선택하는 것이 중요하며, Feature의 개수만으로 Model의 성능을 판단할 수 없다.


5. Which Model Is Better?

세 Model의 Training이 끝났다고 하자.

이제 중요한 질문이 생긴다.

Which model is better?

Model을 비교하려면 Prediction과 실제 Label을 비교해야 한다.



핵심

Model Selection을 위해서는 객관적인 Evaluation Metric이 필요하다.

5-1. Accuracy

가장 직관적인 Classification Metric은 Accuracy이다.

예를 들어 Test Penguin이 20마리이고 18마리를 정확하게 Classification했다면,

$$Accuracy = \frac{18}{20} = 0.9 = 90\%$$

즉 전체 Prediction 중 얼마나 많이 맞혔는지를 측정한다.

핵심

Accuracy는 전체 Prediction 중 Correct Prediction의 비율이다.

5-2. (참고) Accuracy Formula

Binary Classification에서는 Prediction 결과를 네 가지로 나눌 수 있다.

- ▶ True Positive (TP)
- ▶ True Negative (TN)
- ▶ False Positive (FP)
- ▶ False Negative (FN)

Accuracy는 다음과 같이 표현할 수 있다.

$$Accuracy = \frac{TP + TN}{TP + TN + FP + FN}$$

즉 전체 Sample 중 올바르게 Classification한 Sample의 비율이다.

참고

Accuracy는 Correct Prediction을 전체 Prediction으로 나눈 값이다.

6. Confusion Matrix

Accuracy만 보면 어떤 종류의 Error가 발생했는지 알기 어렵다.

Prediction 결과를 네 가지 경우로 나누어보자.

이번 예에서는

Positive = Gentoo

Negative = Adelie

로 정의한다.

	Predicted Gentoo	Predicted Adelie
Actual Gentoo	True Positive	False Negative
Actual Adelie	False Positive	True Negative

핵심

Confusion Matrix는 Model이 어떤 Class를 어떤 방식으로 맞히고 틀렸는지 보여준다.

6-1. True Positive and True Negative

먼저 올바른 Prediction을 살펴보자.

True Positive (TP)

Actual:

Gentoo

Prediction:

Gentoo

실제 Positive를 Positive라고 정확히 Prediction하였다.

True Negative (TN)

Actual:

Adelie

Prediction:

Adelie

실제 Negative를 Negative라고 정확히 Prediction하였다.

핵심

True는 Prediction이 실제 Label과 일치했다는 의미이다.

6-2. False Positive and False Negative

이번에는 잘못된 Prediction을 살펴보자.

False Positive (FP)

Actual:

Adelie

Prediction:

Gentoo

실제로는 Negative인데 Positive라고 잘못 Prediction하였다.

False Negative (FN)

Actual:

Gentoo

Prediction:

Adelie

실제로는 Positive인데 Negative라고 잘못 Prediction하였다.

핵심

False Positive와 False Negative는 서로 다른 종류의 Classification Error이다.

6-3. How to Read TP, FP, FN, TN

TP, FP, FN, TN이 헷갈린다면 두 단어를 나누어서 생각하면 된다.

True / False

Prediction이 맞았는가?

Positive / Negative

Model이 어떤 Class라고 Prediction했는가?

예를 들어,

False Positive

False = Prediction이 틀림

Positive = Gentoo라고 Prediction

핵심

True/False는 Prediction의 정답 여부, Positive/Negative는 Prediction한 Class를 나타낸다.

6-4. Example: Confusion Matrix

Test Data에 40마리의 Penguin이 있다고 하자.

	Predicted Gentoo	Predicted Adelie
Actual Gentoo	17	3
Actual Adelie	2	18

따라서,

- ▶ TP = 17
- ▶ FN = 3
- ▶ FP = 2
- ▶ TN = 18

Correct Prediction은

$$17 + 18 = 35$$

개이다.

따라서 Accuracy는

$$\frac{35}{40} = 0.875 = 87.5\%$$

이다.

7. Precision

Model이 Gentoo라고 Prediction한 Penguin만 생각해보자.

Predicted Gentoo



19 Penguins

17 Actual Gentoo

2 Actual Adelie

질문은 다음과 같다.

“Gentoo라고 한 것 중
실제로 Gentoo는 얼마나 되는가?”

이를 Precision이라고 한다.

핵심

Precision은 Positive라고 Prediction한 것 중 실제로 Positive인 비율이다.

7-1. (참고) Precision Formula

Precision은 다음과 같이 계산한다.

$$Precision = \frac{TP}{TP + FP}$$

앞의 Example에서는

$$TP = 17, \quad FP = 2$$

이므로,

$$Precision = \frac{17}{17 + 2} = \frac{17}{19} \approx 0.895$$

이다.

즉 Gentoo라고 Prediction한 Penguin 중 약 89.5%가 실제 Gentoo였다.

참고

Precision은 Positive Prediction의 신뢰도를 나타내는 Metric으로 생각할 수 있다.

Thank You

Questions?